

Statistica Descrittiva

ADCOM 2025-2026

Filippo Gambarota PhD 

filippo.gambarota@unipd.it

Università di Padova

Ultimo aggiornamento: 03-12-2026

Statistiche, parametri, popolazioni e campioni

Popolazione e campioni

La popolazione è l'insieme di riferimento/target dal quale eventualmente estraiamo il nostro campione. La popolazione può essere infinita o finita. Nella maggior parte dei casi, pur essendo in linea di principio finita (ad esempio le persone iscritte a Unipd) si lavora comunque su un campione.

Tramite **campionamento**, il **campione** viene selezionato/estratto dalla popolazione e diventa oggetto di misurazione e analisi. Pur essendoci diversi tipi di campionamento, la caratteristica fondamentale è la **rappresentatività**.

Un campione rappresentativo viene definito come **un'immagine ridotta e fedele** della popolazione da cui è stato estratto. L'altra caratteristica importante di un campione è la **numerosità** (che indichiamo con N) che indica il numero di unità statistiche.

Statistiche e parametri

La popolazione di riferimento è associata ad alcune caratteristiche *incognite* chiamate **parametri** e solitamente rappresentati con lettere greche μ , σ , etc.

Una **statistica** è una caratteristica del campione. Mentre il parametro (ad esempio l'altezza media) è *incognito*, la statistica (altezza media del campione) è nota e calcolabile. Le statistiche sono stimatori dei parametri incogniti e si indicano solitamente con lettere latine minuscole ($\bar{x}$, s^2 , etc.).

Il concetto di **stima** è sempre e inevitabilmente associato al concetto di errore. L'errore può essere di tipo sistematico e/o casuale. Una buona stima (fatta su un campione) non ha un errore sistematico e riduce il più possibile quello casuale.

Esempi di statistiche

Qualsiasi operazione applicata su un campione che ne descrive una caratteristica è definita come una statistica che, con un certo grado di errore, stima il rispettivo parametro della popolazione. Ad esempio:

- media
- mediana
- massimo
- minimo
- ...

Sono tutte statistiche calcolate su un campione che descrivono parametri della popolazione.

Statistiche come domande

Le statistiche quindi sono dei modi per ridurre la **complessità** di un certo dato ed **estrarre delle informazioni di interesse**.

Un modo interessante di vederle è come se fossero delle **domande** fatte ai nostri dati. Queste domande sono fatte in modo molto mirato e forniscono risposte molto mirate.

La qualità, i limiti e la quantità di informazione della risposta sono funzione di quanto la domanda è adatta a quello che veramente voglio. In un certo senso possiamo parlare di *validità* delle statistiche.

Statistiche come riduzione di complessità


Le statistiche permettono di riassumere centinaia, migliaia, milioni di dati in pochi numeri. Il prezzo da pagare è quello di capire esattamente:

- il significato di quella statistica
- i limiti e le criticità di quella statistica
- il fatto che sto perdendo informazione (ridurre la complessità = perdita informazione)
- il fatto che più statistiche sono sempre meglio di una sola (minore riduzione di complessità)

Come analogia, un abstract o riassunto di un articolo è molto cognitivamente conveniente per avere un'idea generale. Per capire veramente l'argomento è necessario leggerlo interamente e magari leggerne più di uno.


Un esempio

Immaginiamo di avere tutta la popolazione Padovana e di voler capire il numero di cocktails bevuti a settimana in funzione dell'età. Qui vediamo la distribuzione marginale dell'età:




Un esempio

Qui vediamo la distribuzione marginale dei cocktails. La media è di circa 7.5:




Un esempio

Infine vediamo la relazione tra cocktail ed età in fasce:




Un esempio

Ora immaginiamo di selezionare un campione di $N = 500$ da questa popolazione in modo totalmente casuale. La media è di circa 7.4:




Un esempio

Vediamo invece, campionando in modo non casuale, selezionando con più probabilità giovani (< 30 anni) La media è di circa 9.5:



Un esempio




Un esempio

Per stimare in modo adeguato il parametro media di cocktails bevuti nella popolazione di riferimento, il campione dovrebbe essere rappresentativo per tutte quelle caratteristiche che hanno un impatto (età in questo caso).

Popolazione				Campione Rap.				Campione non Rap.			
age	%	drinks	avg	age	%	drinks	avg	age	%	drinks	avg
< 20	0.2	10	8	< 20	0.2	10	7	< 20	0.3	10	10
20-30	0.4	10	8	20-30	0.4	10	7	20-30	0.6	10	10
30-40	0.2	5	8	30-40	0.2	5	7	30-40	0	5	10
40-50	0.1	4	8	40-50	0.1	4	7	40-50	0	4	10
> 50	0.1	1	8	> 50	0.1	1	7	> 50	0	1	10

Exploratory data analysis (EDA)

EDA, the big picture



EDA, principi

In generale, l'esplorazione (dovrebbe) è il primo passo quando si affronta un dataset. Anche nell'esplorazione ci sono degli step, quello che consiglio:

1. Individuare chiaramente la tipologia di variabile/i
2. Rappresentare con un grafico (*adeguato*)
3. Calcolare statistiche descrittive (*adeguate*)
4. Eventualmente integrare grafici e statistiche

Un esempio, Di Marco et al. (2020)

Di Marco, G., Hichy, Z., & Sciacca, F. (2020). Dataset on the relationship between psychosocial resources of volunteers and their quality of life. *Data in Brief*, 30, 105522. <https://doi.org/10.1016/j.dib.2020.105522>

Di Marco et al. (2020) esamina come le risorse psicosociali dei volontari (inclusi benessere professionale, senso di comunità ed esperienze traumatiche) siano correlate alla loro qualità della vita complessiva. I dati sono disponibili direttamente sul sito della rivista [link](#). Ho pulito e sistemato un pochino il dataset, lo potete trovare qui <https://stat-teaching.github.io/adcom/#data> oppure al QR code.



0. Dataset

Intanto le prime cose da fare sono quelle di capire quante righe e quante colonne ha il dataset. In questo caso abbiamo 96 righe (osservazioni/soggetti) e 24 colonne (variabili).

Importare un dataset

Importare un dataset è il primo step e non è sempre un'operazione semplice.
Ho preparato del materiale riguardo gestione dei file e importare dati in R.
Trovate le slide qui:



1. Tipologia di variabili

Proviamo ad esplorare ed individuare qualche tipologia di variabili.

- `education`
- `age`
- `residence`
- `attachment` (in questo caso intesa come senso di comunità)

1. Tipologia di variabili

- **education**: è una variabile **ordinale** con 3 modalità (o livelli) `sec_school` < `high_school` < `degree`.
- **age**: è una variabile **numerica** su **scala a rapporti**. In questo caso espressa in anni (quindi numeri interi).
- **residence**: è una variabile **nominale** (o categoriale) con 3 modalità (o livelli) `north`, `central` e `south`
- **attachment**: tecnicamente è una media o somma di *item* ordinali. Nella pratica (ma ci sono obiezioni) viene considerata una **scala ad intervalli**.

Esplorazione univariata

Con esplorazione **univariata** si intende esplorare una o più variabili **singolarmente** ovvero senza considerare allo stesso tempo altre variabili. L'obiettivo è quello di:

- assicurarsi che la variabile sia stata correttamente interpretata dal software che stiamo utilizzando
- controllare la presenza di errori, valori anomali e/o impossibili
- controllare la presenza di dati mancanti
- esplorare caratteristiche della variabile usando **statistiche descrittive**

Presenza di errori e/o valori anomali

Questo punto è molto importante. La presenza di valori anomali o errori può impattare notevolmente le analisi ed i risultati (vedremo poi un esempio). Un punto di partenza è:

- **ci sono dei limiti (in senso matematico) oggettivi nella variabile?** Ad esempio, avere nella variabile età valori molto alti (70-80) quando ho raccolto dati nelle scuole o avere valori impossibili (e.g., 200). Soprattutto se i dati sono raccolti o inseriti manualmente può succedere.
- **ci sono dei valori anomali in termini di tipologia di dato?** Ad esempio lettere o stringhe dove dovrebbero esserci numeri e viceversa? Questo può essere molto problematico.

Presenza di errori e/o valori anomali

- **Soprattutto per i questionari, il massimo e minimo sono consistenti?** Se un questionario ha 10 item con likert 1-5, il minimo è 10 ed il massimo è 50. Valori minori o maggiori sono probabilmente errori o dati mancanti.
- **Ci sono dati mancanti?** Quanti sono, dove, e se possibile capire il motivo. I partecipanti potevano non rispondere? Sono errori di salvataggio/inserimento? Possono avere un significato o sono totalmente casuali? I dati mancanti possono essere molto problematici.

Statistiche descrittive

Una statistica descrittiva è una funzione dei dati osservati che ha lo scopo di riassumere, sintetizzare o rappresentare in modo compatto le caratteristiche principali di un insieme di dati. Quindi:

- è una funzione → un insieme di calcoli
- riassumere/sintetizzare → di solito 1/2 valori che rappresentano una proprietà specifica
- è di natura descrittiva, senza l'obiettivo di trarre conclusioni o inferenze

? Question Time

Conoscete qualche statistica descrittiva?

Misure di tendenza centrale

Misure di tendenza centrale

Le statistiche di tendenza centrale restituiscono un valore rappresentativo o *centrale* di una distribuzione di dati. Questo valore può essere posizionato al centro, rappresentare un valore tipico o quello più ricorrente. Solitamente ci sono tre principali statistiche di tendenza centrale:

- Media
- Mediana
- Moda

Media

L' Eq. 1 illustra come calcolare la media di una variabile x misurata su un campione di numerosità n .

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

Quindi prendiamo tutti (n) gli x , sommiamo i loro valori e dividiamo per il numero n . Quello che otteniamo è un valore che, sulla scala della variabile, rappresenta la quantità media.


Off-topic: come leggere le formule

Useremo poche formule ma è importante avere una notazione chiara e consistente e saperla leggere. Una volta che è abbastanza chiaro, le formule sono un modo sintetico ed efficace di rappresentare un concetto complesso.

- x è una variabile generica, può essere qualsiasi lettera (latina solitamente)
- La barra sopra $\bar{x}$ indica solitamente la media della variabile x
- $\sum_{i=1}^n$ indica che facciamo la somma partendo da $i = 1$. Quindi
 $i = 1 \quad x_1$, poi $i = 2 \quad x_1 + x_2$, $i = 3 \quad x_1 + x_2 + x_3$ fino a
 $i = n \quad x_1 + x_2 + \dots + x_n$.

Media

Secondo voi, la media di questa distribuzione di dati dove si potrebbe posizionare? Perché?



Media

In R la media si calcola con la funzione `mean` oppure manualmente con la funzione `sum` e `length`:

```
head(dimarco2020$age, 10)
```

```
[1] 53 60 40 57 60 46 53 33 48 60
```

```
mean(dimarco2020$age)
```

```
[1] 49.29167
```

```
sum(dimarco2020$age)/length(dimarco2020$age)
```

```
[1] 49.29167
```


Quantili


I quantili sono un modo per dividere in base all'ordine una certa variabile. Per calcolare un certo quantile Q_p con $p \in (0, 1)$ è necessario:

- ordinare i dati in senso crescente
- calcolare la proporzione di dati minore o uguale a p
- il valore associato Q è il p -esimo quantile

Di solito si utilizzano i percentili ovvero si esprimono in percentuale ma la logica è la stessa. Ad esempio $Q_{40} = x$ indica che il valore x ha il 40% di dati che sono minori o uguali


Quantili

Facciamo un esempio con la variabile x che rappresenta il numero di errori in un test cognitivo:




Quantili

Aggiungiamo i percentili Q_{10} , Q_{50} , Q_{70} , Q_{90} direttamente sull'istogramma:




Quantili

Un modo più diretto di rappresentare e capire i quantili/percentili è il grafico della distribuzione cumulata empirica dei dati.



Quantili

Per combinare quantili ed istogramma, possiamo rappresentare in questo modo. Vedete che ad ogni step è come aggiungere l'altezza dell'istogramma.



Mediana

I quantili ci permettono di capire immediatamente il concetto di mediana. La mediana è il valore al di sotto (e quindi anche al di sopra) del quale abbiamo il 50% dei dati. In pratica corrisponde al 50-esimo Q_{50} percentile. Vediamo in R:

```
# 25esimo, 50esimo e 75esimo percentile  
quantile(dimarco2020$age, c(0.25, 0.5, 0.75))
```

```
25% 50% 75%  
41  50  57
```

```
median(dimarco2020$age)
```

```
[1] 50
```

Questo significa che il 50% dei soggetti ha un'età minore o uguale a 50 anni.

Mediana, precisazione

Quando la numerosità n è dispari la mediana è sempre un valore esistente (ad esempio 50 anni). Quando n è pari, la mediana non è un valore esistente. In questo caso si prende la media dei due valori adiacenti.


$$x = [18_1, 33_2, 35_3, 36_4, 44_5, \mathbf{48_6}, 53_7, 55_8, 59_9, 60_{10}, 93_{11}] \quad n = 11$$

$$x = [18_1, 33_2, 35_3, 36_4, \mathbf{44_5}, \mathbf{48_6}, 53_7, 55_8, 59_9, 60_{10}] \quad n = 10$$

In questo secondo caso la mediana è $\frac{44+48}{2} = 46$


Media e mediana

Prendiamo la variabile `age` del dataset `dimarco2020` e rappresentiamola graficamente:




Media e mediana

Ora possiamo aggiungere la media e la mediana sul grafico. I valori sono abbastanza simili perchè la distribuzione è abbastanza simmetrica.



Media e mediana


Vediamo lo stesso ma per una variabile meno simmetrica come `intrinsic`:



Misure di variabilità

Misure di variabilità

Per descrivere una distribuzione di dati le misure di tendenza centrale non sono (spesso) sufficienti. Queste 4 distribuzioni di dati hanno la stessa media.



Misure di variabilità

Per descrivere in modo più esaustivo i dati abbiamo bisogno di indici che ci informino sulla **dispersione** (o variabilità) attorno agli indici di tendenza centrale. Alcuni indici comunemente usati:

- Range
- Scarto interquartile (IQR, *interquartile range*)
- Deviazione standard e varianza
- Coefficiente di variazione
- Entropia di Shannon

Range

Il range è la misura più semplice di variabilità e si calcola come la differenza tra massimo e minimo di una distribuzione di dati:

$$R = \max(x) - \min(x)$$

Ovviamente risente molto dei valori estremi prendendo semplicemente il massimo e minimo a prescindere da come sono concentrati i valori.

Range

In R calcolare il range è molto semplice:

```
max(x) - min(x)
```

```
[1] 13
```

```
range(x)
```

```
[1]  0 13
```

```
diff(range(x))
```

```
[1] 13
```

Range

Vediamo come la presenza di qualche valore estremo faccia cambiare completamente il range. Comunque è informativo della gamma dei dati.

