

Statistica Descrittiva

ADCOM 2025-2026

Filippo Gambarota PhD 

filippo.gambarota@unipd.it

Università di Padova

Ultimo aggiornamento: 03-11-2026

Statistiche, parametri, popolazioni e campioni

Popolazione e campioni

La popolazione è l'insieme di riferimento/target dal quale eventualmente estraiamo il nostro campione. La popolazione può essere infinita o finita. Nella maggior parte dei casi, pur essendo in linea di principio finita (ad esempio le persone iscritte a Unipd) si lavora comunque su un campione.

Tramite **campionamento**, il **campione** viene selezionato/estratto dalla popolazione e diventa oggetto di misurazione e analisi. Pur essendoci diversi tipi di campionamento, la caratteristica fondamentale è la **rappresentatività**.

Un campione rappresentativo viene definito come **un'immagine ridotta e fedele** della popolazione da cui è stato estratto. L'altra caratteristica importante di un campione è la **numerosità** (che indichiamo con N) che indica il numero di unità statistiche.

Statistiche e parametri

La popolazione di riferimento è associata ad alcune caratteristiche *incognite* chiamate **parametri** e solitamente rappresentati con lettere greche μ , σ , etc.

Una **statistica** è una caratteristica del campione. Mentre il parametro (ad esempio l'altezza media) è *incognito*, la statistica (altezza media del campione) è nota e calcolabile. Le statistiche sono stimatori dei parametri incogniti e si indicano solitamente con lettere latine minuscole ($\bar{x}$, s^2 , etc.).

Il concetto di **stima** è sempre e inevitabilmente associato al concetto di errore. L'errore può essere di tipo sistematico e/o casuale. Una buona stima (fatta su un campione) non ha un errore sistematico e riduce il più possibile quello casuale.

Esempi di statistiche

Qualsiasi operazione applicata su un campione che ne descrive una caratteristica è definita come una statistica che, con un certo grado di errore, stima il rispettivo parametro della popolazione. Ad esempio:

- media
- mediana
- massimo
- minimo
- ...

Sono tutte statistiche calcolate su un campione che descrivono parametri della popolazione.

Statistiche come domande

Le statistiche quindi sono dei modi per ridurre la **complessità** di un certo dato ed **estrarre delle informazioni di interesse**.

Un modo interessante di vederle è come se fossero delle **domande** fatte ai nostri dati. Queste domande sono fatte in modo molto mirato e forniscono risposte molto mirate.

La qualità, i limiti e la quantità di informazione della risposta sono funzione di quanto la domanda è adatta a quello che veramente voglio. In un certo senso possiamo parlare di *validità* delle statistiche.

Statistiche come riduzione di complessità


Le statistiche permettono di riassumere centinaia, migliaia, milioni di dati in pochi numeri. Il prezzo da pagare è quello di capire esattamente:

- il significato di quella statistica
- i limiti e le criticità di quella statistica
- il fatto che sto perdendo informazione (ridurre la complessità = perdita informazione)
- il fatto che più statistiche sono sempre meglio di una sola (minore riduzione di complessità)

Come analogia, un abstract o riassunto di un articolo è molto cognitivamente conveniente per avere un'idea generale. Per capire veramente l'argomento è necessario leggerlo interamente e magari leggerne più di uno.


Un esempio

Immaginiamo di avere tutta la popolazione Padovana e di voler capire il numero di cocktails bevuti a settimana in funzione dell'età. Qui vediamo la distribuzione marginale dell'età:




Un esempio

Qui vediamo la distribuzione marginale dei cocktails. La media è di circa 7.5:




Un esempio

Infine vediamo la relazione tra cocktail ed età in fasce:




Un esempio

Ora immaginiamo di selezionare un campione di $N = 500$ da questa popolazione in modo totalmente casuale. La media è di circa 7.7:




Un esempio

Vediamo invece, campionando in modo non casuale, selezionando con più probabilità giovani (< 30 anni) La media è di circa 9.5:



Un esempio



Un esempio

Per stimare in modo adeguato il parametro media di cocktails bevuti nella popolazione di riferimento, il campione dovrebbe essere rappresentativo per tutte quelle caratteristiche che hanno un impatto (età in questo caso).

Popolazione				Campione Rap.				Campione non Rap.			
age	%	drinks	avg	age	%	drinks	avg	age	%	drinks	avg
< 20	0.2	10	8	< 20	0.2	10	8	< 20	0.3	10	10
20-30	0.4	10	8	20-30	0.4	10	8	20-30	0.6	10	10
30-40	0.2	5	8	30-40	0.2	5	8	30-40	0	5	10
40-50	0.1	4	8	40-50	0.1	4	8	40-50	0	4	10
> 50	0.1	1	8	> 50	0.1	1	8	> 50	0	1	10

Exploratory data analysis (EDA)

EDA, the big picture

