

# Inferenza statistica

ADCOM 2025-2026


Filippo Gambarota PhD 

[filippo.gambarota@unipd.it](mailto:filippo.gambarota@unipd.it)

Università di Padova

*Ultimo aggiornamento: 03-18-2026*

# Inferenza, the big picture



# Inferenza

L'inferenza è un aspetto distinto ma legato al concetto di **stima**. L'inferenza riguarda un processo **decisionale** rispetto ad un **parametro stimato**.

Fare inferenza quindi significa *prendere una decisione basandosi su una o più stime campionarie di parametri*. Essendo l'inferenza basata su stime, la decisione inferenziale ha, per definizione, una componente d'errore.

In altri termini, quando si prende una decisione inferenziale (e.g., il trattamento funziona di più nel gruppo sperimentale, la correlazione è diversa da zero, etc.) è sempre necessario essere consapevoli della componente d'errore.

# Approcci di inferenza statistica

L'inferenza statistica è caratterizzata sia storicamente ma anche attualmente da approcci diversi che possiamo riassumere in:

- Approccio **Fisheriano**
- Approccio di **Neyman & Pearson**
- Approccio basato sulla **Likelihood** (*verosimiglianza*)
- Approccio **Bayesiano**

Diciamo che in Psicologia, viene utilizzato un ibrido tra l'approccio Fisheriano e quello di Neyman & Pearson chiamato Null Hypothesis Significance Testing (NHST) e in minoranza l'approccio Bayesiano.

Noi ci baseremo sull'approccio di Neyman e Pearson, anche se non introdurremo formalmente tutti gli aspetti.

# Per approfondire [#extra]

Per approfondire i problemi legati all'inferenza in Psicologia:

Gigerenzer, G. (1993). The Superego, the Ego, and the Id in Statistical Reasoning. In *A Handbook for Data Analysis in the Behavioral Sciences*. Psychology Press. <https://doi.org/10.4324/9781315799582>



Gigerenzer, G. (2018). Statistical rituals: The replication delusion and how we got there. *Advances in Methods and Practices in Psychological Science*, 1, 198–218. <https://doi.org/10.1177/2515245918771329>



# Errore di stima

# Errore di stima

Il concetto principale per capire l'inferenza è quello di **errore di stima**. Possiamo distinguere due tipologie principali di errori di stima:

- **errore sistematico**: la mia stima è sistematicamente minore o inferiore rispetto al valore vero (*parametro*) che voglio stimare
- **errore casuale**: la mia stima è *in media* corretta ma qualche volta risulta maggiore, qualche volta minore in modo casuale

Tendenzialmente quando si analizzano dati, si cerca di usare metodi che evitano l'errore di tipo sistematico e riducono più possibile quello casuale. Quando abbiamo detto che la misurazione (o stima) di qualcosa è  $D = M + E$  (dati osservati = modello + errore), l'errore  $E$  che consideriamo è di tipo casuale.

# Stima, popolazione e campione

Ritornando a parametri e statistiche, ogni statistica è una stima (con errore) del rispettivo parametro della popolazione.

Quando calcoliamo una media, una deviazione standard, etc. su un campione ricordiamoci sempre che, in ottica di stima, c'è una quota di incertezza. In modo generico definiamo  $\theta$  come il parametro incognito che stiamo stimando e  $S$  la sua stima fatta sul campione.

Chiamiamo  $E$  l'errore di stima ovvero una quantità che determina la precisione con cui  $S$  è una stima di  $\theta$ . Questa quantità viene anche chiamata **errore standard**.



# Dataset

Per capire al meglio il concetto di errore standard, facciamo un esempio con dei dati veri. Usiamo i dati del questionario fatto il primo giorno.

Trovate il dataset su Moodle o su <https://stat-teaching.github.io/adcom/#data>.

Per rendere l'esempio ancora più efficace ho esteso il dataset moltiplicando le righe.

# Dataset

```
library(readxl)
dat <- read_xlsx("data/adcom.xlsx")
```

```
nrow(dat)
```

```
[1] 396
```

```
ncol(dat)
```

```
[1] 7
```

```
head(dat)
```

|   | id | altezza | scarpe | coffee | sex       | residence | analisi |
|---|----|---------|--------|--------|-----------|-----------|---------|
| 1 | 1  | 170     | 41     | 1      | Femminile | Nord-est  | 5       |
| 2 | 2  | 157     | 38     | 2      | Femminile | Nord-est  | 4       |
| 3 | 3  | 165     | 39     | 1      | Femminile | Sud       | 4       |
| 4 | 4  | 168     | 40     | 3      | Femminile | Nord-est  | 4       |
| 5 | 5  | 165     | 39     | 2      | Femminile | Nord-est  | 3       |
| 6 | 6  | 165     | 39     | 2      | Femminile | Nord-est  | 3       |

# Errore standard

Più formalmente ed in modo generico, possiamo dire che l'errore standard di una statistica è:

$$SE = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}$$

Sostanzialmente quindi l'errore standard dipende dalla variabilità intrinseca di un fenomeno  $\sigma^2$  e dal numero di osservazioni  $n$  utilizzate per stimare questo fenomeno.

# Errore standard

Facciamo un esempio decomponendo la formula, se prendiamo due variabili del nostro dataset e vediamo la variabilità (con coefficiente di variazione):

```
sd(dat$scarpe) / abs(mean(dat$scarpe))
```

```
[1] 0.0577459
```

```
sd(dat$coffee) / abs(mean(dat$coffee))
```

```
[1] 0.8430582
```

Vediamo che la variabilità del numero di caffè bevuti è molto maggiore rispetto al numero di scarpe. Quindi, a parità di campione, la stima del numero di caffè bevuti sarà sempre più incerta. Tuttavia, aumentando il denominatore ( $n$ ) possiamo diminuire il nostro errore casuale facendo variare meno la stima. Questo rapporto tra variabilità e numerosità è fondamentale per capire la qualità delle stime.

# Errore standard della media

Abbiamo visto dallo script che l'errore standard della media si calcola come:

$$SE = \sqrt{\frac{\sigma^2}{n}} = \frac{\sigma}{\sqrt{n}}$$

Ovviamente  $\sigma^2$  (la varianza della popolazione) viene stimata anch'essa dal campione. E' importante capire che ogni statistica ha un suo errore standard che segue sempre questa logica. Le formule possono essere diverse (e non è necessario saperle) ma è sempre un rapporto tra varianza del fenomeno e numero di osservazioni usate per la stima.

# Errore standard, nella pratica

A cosa serve l'errore standard nella pratica? Fondamentalmente a due processi:

- misurare e quindi comunicare l'errore di stima, fatta su un campione, di un certo parametro della popolazione
- prendere una decisione *inferenziale* riguardo il parametro, partendo dalla stima fatta sul campione. Non prendiamo una decisione sul campione (quello è noto, non incerto) ma sul parametro della popolazione. La decisione quindi è anch'essa incerta per definizione.

# Distribuzione campionara

Un'altro concetto illustrato nell'esempio è quello di **distribuzione campionaria**. Nell'ipotesi di poter ripetere una misurazione un numero infinito (o molto elevato di volte) la distribuzione campionaria di una statistica è la distribuzione che si ottiene applicando quella statistica a tutti i campioni estratti. E' un concetto teorico, nella pratica non possiamo ri-fare una misurazione infinite volte (a parte con le simulazioni, come nell'esempio)

1. la media delle stime fatte su tutti i campioni possibili coincide con il parametro vero
2. la deviazione standard delle stime (deviazione standard della distribuzione campionaria) rappresenta l'errore di stima

Chiaramente la stima in questo caso non ha errore sistematico (altrimenti 1 non sarebbe vero).

# Distribuzione campionara

Possiamo indicare in modo generico la distribuzione campionaria di una statistica come:

$$S \sim \mathcal{D}(\boldsymbol{\nu})$$

Dove  $\sim$  significa *distribuita come*,  $\mathcal{D}$  è una certa distribuzione (esempio la Normale) e  $\boldsymbol{\nu}$  è un vettore di uno o più parametri (nel caso della Normale,  $\mu$  e  $\sigma$ ).

Questa formulazione generica è solo utile a chiarire che il concetto di distribuzione campionaria è lo stesso ma  $\mathcal{D}$  può essere diverse cose. Nel t-test, ad esempio,  $\mathcal{D}$  è una t di Student.



# Teorema del limite centrale

In alcuni casi, vale un teorema che si chiama **teorema del limite centrale (TLC)**. Il teorema dice che con una numerosità campionaria sufficientemente grande<sup>1</sup>, la distribuzione campionaria di una statistica si può approssimare come una Normale:

$$S \sim \mathcal{N}(\theta, SE_S)$$

Questo si legge come:

La distribuzione campionaria di  $S$  (una statistica generica, e.g., media) è distribuita come ( $\sim$ ) una Normale con media  $\theta$  (il parametro) e deviazione standard l'errore standard.

1. Solitamente, e ci sono motivi statistici la numerosità viene minima viene indicata a 30. Ma diffidate sempre delle soglie arbitrarie.

# Intervallo di confidenza

Un ultimo concetto importante è quello di intervallo di confidenza (CI). Una volta compresa la distribuzione campionaria, l'intervallo di confidenza non è altro un modo di riassumerla, oltre che con la media ma soprattutto con l'errore standard.


Formalmente, l'intervallo di confidenza si calcola come:

$$CI = S \pm qSE_S$$

$S$  è la stima,  $SE_S$  è l'errore standard.  $q$  è un moltiplicatore dell'errore standard. Determina il livello dell'intervallo di confidenza.


# Intervallo di confidenza

Per capire  $q$  dobbiamo ripensare alla normale (dato il TLC). In particolare alla distribuzione normale standard ( $\mu = 0$  e  $\sigma = 1$ ):




# Intervallo di confidenza

Ogni distribuzione (normale) può essere convertita alla normale standard tramite la standardizzazione. Ad esempio, una normale con  $\mu = 100$  e  $\sigma = 15$ :



# Intervallo di confidenza

Quindi ad esempio, un valore  $q = 2$  corrisponde a  $x = \mu + q\sigma = 100 + 2 \times 15 = 130$ :



# Intervallo di confidenza

Ora, esattamente come per i quantili ( $q$  sono quantili infatti) possiamo sapere quale  $q$  è associato ad una certa probabilità cumulata. Solitamente l'intervallo di confidenza si riporta al 5%. Quindi dobbiamo trovare  $q$  dove la probabilità sia  $p(x) \leq q = 0.05$ . Essendo la normale simmetrica, si distribuisce il 5% tra le due code.


```
q <- qnorm(0.05/2, lower.tail = FALSE)
q
```

```
[1] 1.959964
```

Con  $q$  di  $\sim 1.96$  abbiamo una probabilità cumulata (a destra di  $q$  e a sinistra di  $-q$ ) del 2.5%.

# Intervallo di confidenza

Vediamolo sul grafico, evidenziamo l'area.



# Intervallo di confidenza

Tornando al nostro esempio pratico, il CI è l'intervallo sulla distribuzione campionaria che contiene una certa percentuale (e.g., 95%) di valori.

Più formalmente:

L'intervallo di confidenza al  $p\%$  è quell'intervallo che, se ripetessi la misurazione un numero infinito di volte e calcolassi l'intervallo di confidenza, il  $p\%$  delle volte l'intervallo conterrebbe il valore vero  $\theta$ .



# Prendiamo una decisione

Ora, immaginiamo di voler prendere una decisione riguardo un parametro stimato. Ad esempio, facciamo l'inferenza che l'altezza media della popolazione è maggiore di 160cm. Anche qui noi conosciamo la “verità” ma assumiamo di basarci su un campione di numerosità  $n$ . Quindi:

- estraiamo un campione
- calcoliamo l'errore standard e costruiamo la distribuzione campionaria secondo il teorema del limite centrale

```
n <- 30  
idx <- sample(1:nrow(dat), n)  
camp <- dat[idx, ]
```

# Prendiamo una decisione

Calcoliamo le statistiche sul campione:

```
m <- mean(camp$altezza) # media del campione
s <- sd(camp$altezza) # deviazione standard del campione
se <- s / sqrt(n) # errore standard
c(m, s, se)
```

```
[1] 165.833333  8.630672  1.575738
```

Ora possiamo anche costruire l'intervallo di confidenza al 95%, assumendo la normalità della distribuzione campionaria:


```
q <- abs(qnorm(0.05/2)) # teniamolo positivo

ci <- c(
  lb = m - q * se,
  ub = m + q * se
)
ci
```

```
      lb      ub
162.7449 168.9217
```

# Prendiamo una decisione

Visualizziamo anche la distribuzione campionaria, in blu l'intervallo di confidenza e in rosso il valore di confronto.



# Prendiamo una decisione


Come prendiamo una decisione? La prima cosa che possiamo notare è la consistenza del valore 160cm rispetto alla distribuzione campionaria.

Se ripetessi la misurazione un numero infinito di volte, il valore 160cm sarebbe poco probabile.

In modo intuitivo, possiamo dire che sembra esserci evidenza che il valore 160cm sia poco consistente. Infatti la maggior parte delle medie è maggiore di 160.

# Prendiamo una decisione

Vediamola in modo diverso. Immaginiamo un mondo dove la media della popolazione è nota ed è 160cm. Possiamo costruire la stessa distribuzione campionaria ma centrata su 160 e non sulla media del campione.



# Prendiamo una decisione

Allo stesso modo possiamo dire che, se la popolazione avesse una media di 160cm, ottenere un campione con media  $\bar{x}$  165.83 è poco probabile.

Possiamo anche calcolare la probabilità di ottenere un risultato uguale o maggiore a quello ottenuto, nell'ipotesi che la media della popolazione sia 160cm.

```
options(scipen = 999) # per togliere notazione scientifica  
pnorm(m, mean = 160, sd = se, lower.tail = FALSE)
```

```
[1] 0.0001069663
```

Questa probabilità che abbiamo calcolato, si chiama **p value**.

# Statistica test

Solitamente non si lavora con le statistiche grezze ma si calcola una statistica test (come la statistica  $t$  ad esempio). Questa statistica test, come tutte le altre, ha una distribuzione campionaria e quindi un errore standard. Ad esempio:

$$z = \frac{\bar{x} - \mu}{SE_{\bar{x}}}$$

Questa statistica test semplicemente standardizza la differenza tra la media del campione e la media della popolazione che ipotizziamo (per il confronto) dividendo per l'errore standard.

# Prendiamo una decisione

Il vantaggio è che, a prescindere da  $\bar{x}$  e  $\mu$ , questa statistica test standardizzata ha sempre la stessa distribuzione campionaria:

$$z = \frac{\bar{x} - \mu}{SE_{\bar{x}}}$$

$$z \sim \mathcal{N}(0, 1)$$

Ovvero una normale standard ( $\mu = 0, \sigma = 1$ ). Infatti possiamo calcolare il **p value**:


```
mu <- 160  
z <- (m - mu)/se  
pnorm(z, mean = 0, sd = 1, lower.tail = FALSE)
```

```
[1] 0.0001069663
```



# Normale, disclaimer

Questa è la logica per qualsiasi test statistico. Nella pratica a volte si usano altre distribuzioni come la  $t$  di Student. La ragione principale è che l'approssimazione normale, soprattutto per campioni piccoli non è sempre giustificata.



# Errori decisionali

Quello che abbiamo fatto *artigianalmente* è un processo inferenziale:

- Abbiamo definito un'ipotesi nulla  $H_0$  ( $\mu_0 = 160$ , popolazione).
- Basandoci su  $n$  e su  $s$  del campione abbiamo costruito la distribuzione campionaria (assumendo che  $H_0$  sia vera)
- Abbiamo calcolato la probabilità di trovare un risultato uguale o maggiore di quello campionario, ovvero il p value.

Possiamo intuire che tanto più il p value è piccolo tanto più il risultato del campione è *soprendente* assumendo  $H_0$  come vera. Ma quanto piccolo deve essere il p value per rifiutare  $H_0$ ?

# Errori decisionali

Fissiamo questo valore (totalmente a caso 😊) che chiamiamo  $\alpha = 0.05$ . Questa è la nostra soglia decisionale. Se il p value  $p$  è minore di  $\alpha$  allora **arbitrariamente** decidiamo che i dati non sono consistenti con  $H_0$ , e la rifiutiamo.

Al contrario, se  $p$  è maggiore di  $\alpha$  allora non possiamo rifiutare  $H_0$ . Ricordate che non esiste, in questo framework inferenziale, il concetto di accettare  $H_0$ .  $H_0$  è vera per definizione nel momento in cui calcoliamo  $p$ .

Quindi, assumendo vera  $H_0$  significa che c'è sempre una probabilità che per quanto estremo sia il risultato del campione questo venga da una popolazione con media  $\mu_0$ . Rifiutare in questo caso significa commettere un errore inferenziale. Errore noto come falso positivo o errore primo tipo.

# Tutto così semplice?


Non esattamente. Ci sono alcuni problemi con questo approccio:

- Abbiamo definito solo  $H_0$ , non abbiamo ipotesi di come potrebbe essere il mondo alternativo dove  $H_0$  è falsa.
- $p$  si basa su  $z$  (o statistica test in generale) che a sua volta dipende da un numeratore e denominatore. Lo stesso  $p$  si può ottenere con infinite combinazioni.
- $\alpha$  è stato scelto in modo arbitrario

Tutte ma non solo queste problematiche hanno contribuito a quella che viene definita crisi di replicabilità. L'uso improprio dell'inferenza è una delle principali ragioni.

# Tutto così semplice?

Lo stesso p value può essere ottenuto con scenari molto diversi. Quindi il p value da solo non è sufficiente.



# Ipotesi alternativa

Ci manca un'ipotesi alternativa  $H_1$  nei termini di un valore plausibile del parametro  $\mu_1$  nel mondo dove  $H_0$  è falsa e  $H_1$  è vera. Importante, questo non è il valore del campione, ma un valore ipotetico e plausibile del parametro.

Attenzione che dire  $H_0 : \mu = 160$  e  $H_1 : \mu > 160$  non è sufficiente.  $H_1$ , nel momento in cui definiamo l'ipotesi alternativa deve essere un valore definito ed empiricamente plausibile.

Il motivo è che oltre all'errore di primo tipo o falso positivo abbiamo anche altri errori e questi sono definiti quando  $H_1$  è definito.

# Ipotesi alternativa


Restando sull'esempio, immaginiamo che  $H_1 : \mu = 165$ . Quindi la media della popolazione è 170cm e non 160 (il valore *nullo*). Abbiamo quindi due distribuzioni campionarie:

- distribuzione campionaria della statistica test quando  $H_0$  è vera (e quindi  $H_1$  è falsa)
- distribuzione campionaria della statistica test quando  $H_1$  è vera (e quindi  $H_0$  è falsa)

Inoltre abbiamo il nostro valore di  $\alpha$  per la decisione inferenziale. Abbiamo costruito un sistema di verifica di ipotesi molto simile a quello proposto da Neyman e Pearson.

# Ipotesi alternativa

Nel nostro caso, ipotizziamo che  $H_1 : \mu = 165$ . Quindi possiamo disegnare entrambe le distribuzioni.





# Ipotesi nulla e alternativa

Quindi possiamo riassumere questo sistema in una tabella di contingenza 2x2:

|       |       | Test                                        |                                             |
|-------|-------|---------------------------------------------|---------------------------------------------|
|       |       | Rifiuto $H_0$                               | Non rifiuto $H_0$                           |
| $H_0$ | Falsa | Vero Positivo<br>Potenza<br>$1 - \beta$     | Falso Negativo<br>Errore II tipo<br>$\beta$ |
|       | Vera  | Falso Positivo<br>Errore I tipo<br>$\alpha$ | Vero Negativo<br>$1 - \alpha$               |

# Ipotesi nulla e alternativa

Quindi, gli aspetti principali sono:

- $H_0$  e  $H_1$  sono mutualmente esclusive
- La potenza è la probabilità condizionata di rifiutare  $H_0$  quando questa è falsa (quindi assumendo vera  $H_1$ )
- L'errore di primo tipo è la probabilità di rifiutare  $H_0$  quando questa è vera. Viene di solito fissato ad un valore
- il p value è la probabilità di ottenere un risultato uguale o più estremo se  $H_0$  è vera

L'obiettivo di un test è avere più potenza possibile mantenendo un livello accettabile di  $\alpha$ .

# Come si calcola la potenza?

Di base, il calcolo è simile a quello del p value ma basato sull'ipotesi alternativa. Facciamo un esempio<sup>1</sup>:

```
mu0 <- 160
mu1 <- 165
se <- sd(dat$altezza) / sqrt(nrow(camp))
alpha <- 0.05
z <- (mu1 - mu0) / se
z # differenza tra le due ipotesi, standardizzata
## [1] 3.514177

zcrit <- abs(qnorm(alpha/2)) # valore critico standardizzato
zcrit
## [1] 1.959964

# spostiamo i valori critici della normale standard in funzione della
# differenza tra le due ipotesi (H1)
(power <- pnorm(-zcrit + z) + pnorm(zcrit + z, lower.tail = FALSE))
## [1] 0.9399333
```

In questo caso la potenza è 0.94, quindi se fosse vera  $H_1 : \mu = 165$  avremmo probabilità del 94% di trovare l'effetto. Trovare l'effetto qui significa essere in grado di distinguerlo da quello *nullo* ovvero  $\mu_0 = 160$ .

1. Calcolare o stimare la potenza non è sempre così semplice, ma la logica è sempre la stessa.

# Da cosa dipende la potenza?

La potenza dipende fondamentalmente da due aspetti:

- il valore di  $\alpha$ : un valore di  $\alpha$  maggiore significa una statistica test minore (in valore assoluto) e quindi maggiore probabilità di rifiutare  $H_0$ . Però  $\alpha$  generalmente è fisso e deciso a priori.
- il grado di separazione tra le due ipotesi, quindi la statistica test. Questa a sua volta dipende da:
  - numeratore: quindi il grado di separazione *grezzo* delle ipotesi
  - denominatore (errore standard): quindi la numerosità campionaria  $n$  e  $\sigma$  ovvero il grado di variabilità del fenomeno.

Quindi nella pratica, essendo  $\alpha$  definito a priori, la separazione tra le ipotesi  $\mu_1 - \mu_0$  definito a priori e  $\sigma$  stimato ( $s$ ), l'aspetto cruciale è la numerosità campionaria  $n$ .

# Effect size

Un ultimo aspetto importante nell'inferenza è il concetto di effect size.

L'effect size non è altro che una statistica come le altre ma che viene usata essendo direttamente e “facilmente” interpretabile. Ci sono due tipo di effect size:

- **standardizzati**: ad esempio il Cohen's  $d$ , correlazione, odds ratio, etc.  
Sono degli effect size che non dipendono dall'unità di misura originale. A prescindere da cosa sto correlando, una correlazione di 0.5 è interpretata, statisticamente, allo stesso modo.
- **non standardizzati**: ad esempio la differenza semplice tra due medie. Dal punto di vista prettamente statistico sono preferibili ma non sempre sono interpretabili. Dire che due persone differiscono di 15cm in altezza è chiaro (effetto grande). Dire che due persone differiscono di 4 punti su una scala di depressione è meno chiaro.

# Effect size, Cohen's $d$

Un esempio classico riguarda il Cohen's  $d$  (o differenza tra medie standardizzate). Immaginiamo di avere la situazione di prima con  $\mu_0 = 160$  e  $\mu_1 = 165$ . La differenza tra medie *grezza* è  $\Delta = \mu_1 - \mu_0 = 5$ .

Per standardizzare questa differenza tenendo conto del grado di variabilità possiamo dividere  $\Delta$  per la deviazione standard della popolazione  $\sigma$ .

Quindi:

$$\delta = \frac{\mu_1 - \mu_0}{\sigma}$$

Quindi la differenza ora è espressa in unità standardizzate di deviazione standard e non più in centimetri.

# Effect size, Cohen's $d$

Proviamo a calcolarlo:

```
sigma <- sd(dat$altezza) # deviazione standard popolazione  
delta <- (mu1 - mu0) / sigma  
delta
```

```
[1] 0.6415981
```

Quindi  $\mu_1$  è 0.64 deviazioni standard dall'ipotesi nulla. Questo valore è facilmente confrontabile a prescindere dal tipo di variabile.

# Cohen's $d$ e statistica test

Abbiamo definito prima una statistica test come:

$$z = \frac{\mu_1 - \mu_0}{SE_{\mu_1}} = \frac{\mu_1 - \mu_0}{\frac{\sigma}{\sqrt{n}}}$$

La formula è simile ma  $\delta$  non contiene  $n$ . Infatti, l'effect size è semplicemente una trasformazione standardizzata mentre la statistica test ingloba anche l'informazione della numerosità.

Il punto è proprio questo, uno stesso effect size può essere (come per tutte le altre statistiche) stimato più o meno precisamente e quindi avere più o meno errore standard.



# Cohen's $d$

Anche se standardizzato, questo effect size non è facilmente interpretabile come una correlazione (tra -1 e 1). Ci sono dei benchmark che possono essere utili:


- La differenza di altezza media tra maschi e femmine in Olanda è di 13cm o Cohen's  $d = 2$  (Schönbeck et al., 2012)<sup>1</sup>
- Ci sono delle stime degli effect size medi in Psicologia attorno a 0.4 (Richard et al., 2003)

Queste sono solo indicazioni generali, ogni ambito di ricerca può avere degli effetti plausibili. Ovviamente diffidate degli effetti troppo ottimisti, sono poco plausibili.

1. [https://lakens.github.io/statistical\\_inferences/06-effectsizes.html](https://lakens.github.io/statistical_inferences/06-effectsizes.html)


# Cohen's $d$ e potenza

Ora che abbiamo un valore standardizzato per esprimere il grado di separazione delle ipotesi  $H_0$  e  $H_1$ , vediamo come è legato alla potenza.




# Aspetti cricici

Il primo aspetto da tenere a mente è: qualunque effetto (diverso da zero) con un certo  $n$  sarà associato ad un  $p \leq \alpha$ , quindi sarà significativo. Quindi il p value, da solo, non ci dice chiaramente la grandezza (e quindi la rilevanza) dell'effetto.




# Aspetti critici

Allo stesso tempo, se abbiamo campioni di numerosità limitata non è possibile stimare in modo affidabile effetti molto piccoli.



# Aspetti critici

Un ultimo aspetto critico riguarda la **selezione per la significatività**. Se vengono pubblicati solo i risultati con  $p \leq \alpha$  questo porta ad una sovrastima dell'effetto.



# Ricapitolando

Ipotesi nulla

$$H_0 : \theta = \theta_0$$

Ipotesi alternativa

$$H_1 : \theta = \theta_1$$

$$\Delta = \theta_1 - \theta_0 \xrightarrow{\text{Stima}}$$

$$\delta = \frac{\theta_1 - \theta_0}{\sigma}$$

Effect size

Errore standard

$$SE_{\theta_1 - \theta_0} = \frac{\sigma}{\sqrt{n}}$$

Variabilità del fenomeno

Numerosità campionaria

Statistica test

$$t = \frac{\theta_1 - \theta_0}{\frac{\sigma}{\sqrt{n}}} \sim D(\nu)$$

Parametri della distribuzione campionaria

Distribuzione campionaria

(e.g, Normale)

$\alpha$  errore di I tipo

$$1 - \beta = f(\delta, n, \alpha \mid H_1)$$

potenza

$$p = f(t \mid H_0)$$

p-value

Rifiuto  $H_0$  se  $p \leq \alpha$

# Ricapitolando

- L'inferenza dipende dalla grandezza dell'effetto e dalla qualità della stima (errore standard). Effetti più complessi (test ad un campione vs a due campioni) hanno generalmente potenza minore.
- La distribuzione campionaria non è sempre normale. Di solito si usa anche la  $t$  di Student ma la logica generale è la stessa.
- La potenza è una funzione che dipende da diversi parametri. Effetti piccoli (comuni in Psicologia), richiedono campioni grandi.
- Il  $p$  value da solo non è informativo rispetto alla rilevanza statistica ed empirica dell'effetto.
- Effetti grandi con campioni piccoli sono nella maggior parte dei casi sovrastime e non dovrebbero essere considerati affidabili.

# Bibliografia

- Gigerenzer, G. (1993). The Superego, the Ego, and the Id in Statistical Reasoning. In *A Handbook for Data Analysis in the Behavioral Sciences*. Psychology Press. <https://doi.org/10.4324/9781315799582>
- Gigerenzer, G. (2018). Statistical rituals: The replication delusion and how we got there. *Advances in Methods and Practices in Psychological Science*, 1, 198–218. <https://doi.org/10.1177/2515245918771329>
- Richard, F. D., Bond, C. F., Jr, & Stokes-Zoota, J. J. (2003). One hundred years of social psychology quantitatively described. *Review of General Psychology: Journal of Division 1, of the American Psychological Association*, 7, 331–363. <https://doi.org/10.1037/1089-2680.7.4.331>
- Schönbeck, Y., Talma, H., Dommelen, P. van, Bakker, B., Buitendijk, S. E., HiraSing, R. A., & Buuren, S. van. (2012). The world's tallest nation has stopped growing taller: the height of Dutch children from 1955 to 2009. *Pediatric Research*, 73, 371–377. <https://doi.org/10.1038/pr.2012.189>