

Modello di Regressione Lineare

ADCOM 2025-2026

Filippo Gambarota PhD 

filippo.gambarota@unipd.it

Università di Padova

Ultimo aggiornamento: 04-16-2026

Dataset

Lavoriamo sempre sul dataset Di Marco et al. (2020):


```
dat <- readxl::read_xlsx("dimarco2020.xlsx")
```

	id	age	gender	education	status	residence	period	age_cat	period_cat
1	1	53	male	high_school	2	south	31	51-60	>31
2	2	60	male	degree	2	north	27	51-60	21-30
3	3	40	female	degree	2	north	13	31-40	11-15
4	4	57	male	degree	2	north	20	51-60	16-20
5	5	60	male	high_school	2	north	20	51-60	16-20
6	6	46	male	degree	2	north	14	41-50	11-15

	attachment	needs	bonds	perc_collective_efficacy	perc_self_efficacy	family
1		3.67	3.33	3.33	3.2	3.11 3.75
2		4.00	3.33	4.00	4.2	3.95 5.00
3		4.00	2.67	3.50	3.8	3.58 4.25
4		4.00	4.00	3.50	3.6	3.74 4.25
5		3.33	3.00	3.33	3.4	3.53 4.00
6		4.00	3.33	3.33	4.0	3.62 5.00


Relazione lineare

Quando abbiamo parlato di *correlazione*, abbiamo chiarito che due variabili sono correlate se la loro relazione è di tipo *lineare*. Lineare significa che la relazione può essere descritta da una retta. **Ma come disegniamo questa retta?**




Infinite rette

In uno spazio bidimensionale come questo grafico, possiamo disegnare infinite rette:




Come scegliere la retta migliore?

Intuitivamente, l'idea è di prendere una retta che *approssima meglio* la relazione tra le due variabili. Prendiamo come metrica di bontà della retta la distanza dai punti:







Come scegliere la retta migliore?

Per quantificare in un numero questa metrica, eleviamo al quadrato (togliamo il segno) e facciamo la somma. Calcoliamo quindi la devianza o Sum of Squares (SS):



Come scegliere la retta migliore?

Questo valore di per se non ci dice molto ma riassume la somma delle distanze (al quadrato) dalla retta. Facciamolo per diverse rette.




Come scegliere la retta migliore?

Come vediamo, diverse rette producono una diversa SS. Ovviamente, più piccola è la SS e più vicini sono i punti alla retta. Questo è il nostro criterio, dobbiamo trovare la retta che *minimizza* la distanza dei punti (al quadrato).

Questo metodo, dal punto di vista algoritmico, si chiama **metodo dei minimi quadrati** perchè appunto permette di trovare quella retta che minimizza la distanza dai punti (al quadrato).


Come disegnare una retta?

Prima di tutto però è necessario capire come una retta viene definita.
Abbiamo detto che per un piano bidimensionale passano infinite rette.
Allora intanto ancoriamoci ad un punto:



Come disegnare una retta?

Ora immaginiamo che tutte le rette (ancora infinite) passino da quel punto.
Di base ci serve solo definire l'inclinazione della retta.



Come disegnare una retta?

Quindi abbiamo bisogno di soli 2 elementi per disegnare una retta. Un punto di *ancoraggio* e un valore che indichi la pendenza della retta. Questi due valori sono chiamati rispettivamente **intercetta** e **pendenza** o coefficiente angolare (*slope*).


Più formalmente, una retta è definita come:

$$y_i = \beta_0 + \beta_1 x_i$$

Dove β_0 è l'intercetta e β_1 è la pendenza. Nella pratica è una funzione con due parametri che dato un input x fornisce il valore di y . Il valore di y dipenderà dai valori di β_0 e β_1 .

Intercetta

Nella pratica, l'intercetta sposta verticalmente la retta. Qui la pendenza è la stessa ma sto spostando verticalmente tutta la retta.



Disegnare la retta, migliore

Quindi come disegniamo la retta migliore? L'idea è quella di trovare un modo per *minimizzare* la distanza della retta dai punti. In questo modo siamo in grado di stimare i parametri β_0 e β_1 . In particolare, β_1 :

$$\beta_1 = \frac{\sum_{i=1}^n (x - \bar{x})(y - \bar{y})}{\sum_{i=1}^n (x - \bar{x})^2}$$

Invece β_0 :

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Il metodo dei minimi quadrati dimostra che questo modo di calcolare β_0 e β_1 è quello che minimizza le distanze (errori). La dimostrazione è fuori dallo scopo del corso.

Disegnare la retta, migliore

Proviamo a fare il calcolo, con le nostre due variabili:

```
x <- dat$burnout
y <- dat$satisfaction

b1 <- sum((x - mean(x)) * (y - mean(y))) / sum((x - mean(x))^2)
b0 <- mean(y) - b1 * mean(x)
```

```
b0
```

```
[1] 4.83504
```

```
b1
```

```
[1] -0.5072002
```

Anche senza sapere bene come interpretarli, proviamo a disegnare la retta. Per disegnarla riprendiamo la formula generale della retta $y = \beta_0 + \beta_1 x$.

Disegnare la retta, migliore

Per disegnarla prendiamo una serie di valori x e su ogni x applichiamo la formula. Usiamo direttamente i valori di `burnout` (salvati in `x`)

```
head(x)
```

```
[1] 1.8 1.4 2.7 1.9 2.6 2.1
```

```
yn <- b0 + b1 * x
```


```
# questi sono i valori per disegnare la retta
```

```
head(yn)
```

```
[1] 3.922080 4.124960 3.465599 3.871360 3.516319 3.769919
```

Disegnare la retta, migliore

```
plot(x, yn)
```



Cosa sono effettivamente β_0 e β_1 ?

Li abbiamo calcolati e visualizzato la retta, ma cosa vogliono dire quei numeri?

- β_0 (intercetta) è il valore di y (outcome) quando $x = 0$. E' il punto dove la retta interseca l'asse y
- β_1 (pendenza, slope) è l'incremento di y per ogni incremento unitario di x

Mentre β_0 è molto semplice, vediamo meglio β_1 . L'idea è questa, prendiamo un intervallo di valori sulla x , tramite la retta proiettiamo quell'intervallo sulla y . La proiezione su y è il nostro β_1 .

Cosa sono effettivamente β_0 e β_1 ?


Più formalmente, prendiamo due punti a e b sulla retta x e calcoliamo la differenza, chiamiamolo Δ_x . Poi proiettiamo questa differenza su y e calcoliamo la differenza, chiamiamolo Δ_y . Il rapporto tra queste due differenze è β_1 :

$$\beta_1 = \frac{y_a - y_b}{x_a - x_b} = \frac{\Delta_y}{\Delta_x}$$

Quindi, quando $x_a - x_b = 1$ allora:

$$\begin{aligned}y &= \beta_0 + \beta_1 x \\y^* &= \beta_0 + \beta_1(x + 1) \\y^* &= \beta_0 + \beta_1 x + \beta_1 \\y^* &= y + \beta_1\end{aligned}$$

Cosa sono effettivamente β_0 e β_1 ?



Cosa sono effettivamente β_0 e β_1 ?

Quindi in termini pratici:

- β_0 (intercetta) è la stima di *satisfaction* (*outcome*) quando il *burnout* (*predittore*) è zero.
- β_1 (slope) è l'incremento di *satisfaction* per un incremento unitario di *burnout*. Essendo che β_1 è negativo, questo è un decremento.

Ci sono due punti importanti per l'interpretazione dei valori di β_0 e β_1 :

- *burnout* messo a zero potrebbe non essere sensato. Immaginate di avere l'età al posto di *burnout*. β_0 sarebbe il valore di *satisfaction* quando l'età è zero.
- L'incremento unitario di *burnout* deve essere sensato. Se siamo 1 punto in più nella scala di *burnout* è un valore sensato, allora β_1 diventa direttamente interpretabile.

Cosa stiamo effettivamente facendo?

A prescindere dall'aspetto geometrico, cosa significa tracciare una retta e quindi trovare (stimare) i parametri β_0 e β_1 . Per farlo partiamo da un caso particolare ovvero una retta con $\beta_1 = 0$.

Se riprendiamo le formule:


$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

$$\beta_0 = \bar{y}$$

Quindi quando $\beta_1 = 0$, β_0 corrisponde alla media di y (**satisfaction** nel nostro caso).


Cosa stiamo effettivamente facendo?

Questa retta sta ignorando **burnout** ($\beta_1 = 0$). Possiamo calcolare la SS sommando i segmenti rossi (al quadrato). Chiamiamo questa SS, SSE (errore):




Cosa stiamo effettivamente facendo?

Ora se invece che fissare $\beta_1 = 0$, usiamo **burnout** e vediamo se la retta si sposta:



Cosa stiamo effettivamente facendo?

In pratica la distanza tra la retta e i punti è, in media, ridotta. Vediamo per un punto in particolare. Spostare la retta (dalla rossa alla blu) *spiega* una parte della distanza (varianza).



Cosa stiamo effettivamente facendo?

Quindi se chiamiamo SS_E la somma dei quadrati rimasta dopo aver spostato la retta possiamo chiamare SS_T (totale, riga verde) quella prima di spostare la retta. Invece chiamiamo SS_R (regressione) quella che abbiamo tolto (in gergo, *spiegato*, blu). Possiamo quindi scrivere che:

$$SS_T = SS_R + SS_E$$

Quindi i parametri β_0 e β_1 vengono stimati (tramite il metodo dei minimi quadrati) in modo da minimizzare SS_E (o anche per massimizzare SS_R).

$$R^2$$




Inoltre, se SS_T è il nostro totale, possiamo esprimere il quale percentuale SS_R spiega. Chiamiamo R^2 questa percentuale. Formalmente:

$$R^2 = 1 - \frac{SS_E}{SS_T}$$

Chiaramente maggiore è la riduzione di SS_E (la retta si avvicina molto ai punti) maggiore è R^2 .


Intuizione

Un'altro modo di vedere la questione è, partendo dalla retta con $\beta_1 = 0$ (quella orizzontale). Senza un predittore x (**burnout**) la retta che minimizza SS_E è fondamentalmente la media.



Intuizione

Quando inseriamo un predittore `burnout` stiamo implicitamente dicendo che la media di y (`satisfaction`) si può spostare in funzione di `burnout`. Quindi la retta che minimizza è sempre la media ma spostata in funzione di `burnout`:



Più formalmente

Ora che abbiamo idea di cosa sta succedendo, definiamo meglio l'equazione della retta tenendo conto anche dell'errore:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

Dove y_i è il valore *osservato* (di *satisfaction*). La parte $\beta_0 + \beta_1 x_i$ viene anche chiamata componente sistematica perchè definisce semplicemente la retta una volta stimati β_0 e β_1 , senza errore. Il valore osservato è quindi formato dalla parte sistematica e dall'errore.

Errori

Ora, mentre la parte sistematica $\beta_0 + \beta_1 x_i$ per definizione è senza errore è importante ora capire di più riguardo a ϵ_i .

Abbiamo definito nel modulo di inferenza, che quando stimiamo dei parametri c'è sempre una quota d'errore. Inoltre questo **errore**, idealmente, dovrebbe essere di tipo **casuale** e non sistematico.

Quindi gli errori ϵ_i , attorno alla retta (parte sistematica) dovrebbero distribuirsi in modo casuale. In termini pratici i punti dovrebbero essere certe volte maggiori, altre volte minori della retta. La media degli errori quindi dovrebbe essere zero.

Errori


Più formalmente possiamo dire che:

- La media degli errori dovrebbe essere $\mu_{\epsilon} = 0$
- La dispersione degli errori σ_{ϵ} (la varianza/deviazione standard) è per definizione diversa da zero (c'è sempre una quota d'errore) ma aumenta/diminuisce in base a quanto la retta è vicina ai punti.

Quindi un buon modo di descrivere gli errori (idealmente) potrebbe essere quello di immaginare una distribuzione $\epsilon \sim \mathcal{D}(\mu = 0, \sigma_{\epsilon})$.

Errori

Una buona distribuzione potrebbe essere proprio quella **Normale**. Infatti essendo simmetrica le deviazioni dalla media sono per definizione casuali. Deviazioni positive e negative sono bilanciate attorno al centro, ovvero la media.



Errori

Quindi possiamo dire che costruiamo una retta che, tramite β_0 e β_1 minimizza le distanze dai punti. Le distanze *residue* sono distribuite in modo casuale come una distribuzione normale con $\mu = 0$ e deviazione standard σ_ϵ .

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

$$\epsilon_i \sim \mathcal{N}(0, \sigma_{\epsilon_i})$$


Definiamo anche $\hat{y}$ (ovvero y stimato) come:

$$\hat{y}_i = \beta_0 + \beta_1 x_i$$

Ovvero il valore che la retta prevede per l'osservazione i .



Errori, graficamente

Stiamo assumendo che per ogni $\hat{y}_i$, gli errori intorno siano distribuiti come una normale con $\mu = 0$ e deviazione standard σ_ϵ .



Perche $\mu = 0$?

Se provate a sottrarre (*centrare*) da ogni dato osservato y_i il dato previsto dalla retta $\hat{y}_i$ otteniamo questo. La deviazione standard di $y - \hat{y}$ è una stima di σ_ϵ .



Riassumendo

Abbiamo *scomposto* ogni dato osservato y_i come:

$$y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$

Se definiamo $\hat{y} = \beta_0 + \beta_1 x_i$ allora:

$$y_i = \hat{y}_i + \epsilon_i$$

Inoltre, definiamo come **residui**:

$$\epsilon_i = y_i - \hat{y}_i$$

Infine, quando $\beta_1 = 0$ abbiamo visto che:

$$y_i = \beta_0 + \epsilon_i = \bar{y} + \epsilon_i$$